

8INF852 – Métaheuristiques en optimisation

Travail pratique 1 – Rapport

Youssef AITELOURF

Hiver 2026

1 Objectif

Ce travail vise à comparer, dans un cadre *Monte-Carlo*, la performance moyenne et la robustesse de métaheuristiques stochastiques sur un problème réel non convexe, borné et contraint. Les méthodes évaluées sont :

- la recherche aléatoire (baseline),
- le hill-climbing simple $(1 + 1)$,
- le generalized hill-climbing $(1, \lambda)$,
- le recuit simulé avec trois schémas de refroidissement.

2 Problème d'optimisation du ressort

On minimise la fonction :

$$f(\mathbf{x}) = x_1^2 x_2 (2 + x_3) \quad (1)$$

avec les contraintes :

$$g_1(\mathbf{x}) = 1 - \frac{x_2^3 x_3}{71785 x_1^4} \leq 0 \quad (2)$$

$$g_2(\mathbf{x}) = \frac{4x_2^2 - x_1 x_2}{12566(x_2 x_1^3 - x_1^4)} + \frac{1}{5108 x_1^2} - 1 \leq 0 \quad (3)$$

$$g_3(\mathbf{x}) = 1 - \frac{140.45 x_1}{x_2^2 x_3} \leq 0 \quad (4)$$

$$g_4(\mathbf{x}) = \frac{x_1 + x_2}{1.5} - 1 \leq 0 \quad (5)$$

et les bornes :

$$0.05 \leq x_1 \leq 2.00, \quad 0.25 \leq x_2 \leq 1.30, \quad 2.00 \leq x_3 \leq 15.0. \quad (6)$$

La valeur de référence donnée dans l'énoncé est proche de 1.2665×10^{-2} .

2.1 Traitement des contraintes

Le coût optimisé est un coût pénalisé :

$$F(\mathbf{x}) = f(\mathbf{x}) + \rho \left(\sum_{j=1}^4 \max(0, g_j(\mathbf{x})) + v_{\text{bornes}}(\mathbf{x}) \right) \quad (7)$$

avec $\rho = 10^6$.

Ce choix est volontairement simple, linéaire et commun à tous les algorithmes afin de comparer les méthodes sur une même base.

3 Métaheuristiques implémentées

3.1 Recherche aléatoire

À chaque itération, une nouvelle solution uniforme dans les bornes est générée et évaluée. Cette méthode sert de baseline minimale.

3.2 Hill-climbing 1+1

Un seul voisin est généré par perturbation gaussienne autour de la solution courante. Le voisin est accepté uniquement s'il améliore le coût pénalisé.

3.3 Generalized hill-climbing 1-lambda

À chaque itération, λ voisins sont générés ; le meilleur est sélectionné. Cela enrichit l'exploration locale et améliore le compromis exploration/exploitation par rapport au (1 + 1).

3.4 Recuit simulé

Le recuit simulé reprend la génération de voisins et autorise l'acceptation probabiliste de solutions moins bonnes :

$$P(\text{accepter}) = \exp\left(-\frac{\Delta}{T}\right), \quad \Delta > 0. \quad (8)$$

Trois stratégies de refroidissement ont été testées :

- exponentiel,
- linéaire,
- logarithmique.

Un mécanisme de réchauffement est activé en stagnation : retour à la dernière meilleure solution puis augmentation de la température de départ.

4 Protocole expérimental

- Simulations Monte-Carlo par algorithme : 50
- Nombre maximal d'itérations : 2000
- Arrêt secondaire (sauf recherche aléatoire) : 100 itérations sans amélioration significative
- Seuil d'amélioration significative : $\epsilon = 0.001$
- Gestion du hasard : `numpy.random.default_rng`, seed de base 42 avec décalage par run

4.1 Hyperparamètres numériques (reproductibilité)

Les résultats présentés dans ce rapport correspondent exactement aux paramètres suivants :

TABLE 1 – Hyperparamètres utilisés pour toutes les expériences

Paramètre	Valeur
Nombre de runs Monte-Carlo (n)	50
Itérations max	2000
Stagnation max	100
Seuil d’amélioration (ϵ)	0.001
Seed de base	42
Coefficient de pénalité (ρ)	10^6
Échelle du voisinage (<code>step_scale</code>)	0.05
Écart-type par dimension	$\sigma_j = 0.05 (ub_j - lb_j)$
λ (HC généralisé et SA)	10
Température initiale SA (T_0)	1.0
Paramètre de refroidissement (α)	0.995
Température minimale	10^{-6}
Facteur de réchauffement	1.5

Schémas de refroidissement implémentés :

$$T_k^{\text{exp}} = T_0 \alpha^k, \quad (9)$$

$$T_k^{\text{lin}} = \max(T_{\min}, T_0 - \alpha k), \quad (10)$$

$$T_k^{\text{log}} = \frac{T_0}{1 + \alpha \ln(1 + k)}. \quad (11)$$

Sorties générées automatiquement :

- `outputs_main/runs_history.csv`
- `outputs_main/final_statistics.csv`
- `outputs_main/convergence_profile.csv`
- figures de convergence par algorithme et comparative

5 Résultats

5.1 Statistiques finales

Le Tableau 2 présente les statistiques descriptives des coûts finaux (meilleur, médiane, dispersion).

TABLE 2 – Statistiques finales sur 50 simulations Monte-Carlo

Algorithme	Best	Médiane	IQR
<code>random_search</code>	0.014 499	0.023 156	0.007 694
<code>hill_climbing_1p1</code>	0.015 344	0.027 007	0.028 870
<code>hill_climbing_1_lambda</code>	0.013 339	0.014 776	0.001 726
<code>simulated_annealing_exponential</code>	0.012 880	0.013 628	0.000 886
<code>simulated_annealing_linear</code>	0.012 806	0.013 384	0.000 778
<code>simulated_annealing_logarithmic</code>	0.012 809	0.013 907	0.000 680

5.2 Profils de convergence







FIGURE 1 – Comparaison interalgorithmes des profils de convergence (médiane).




(a) Recherche aléatoire




(b) HC (1 + 1)




(c) HC (1, λ)



(d) SA exponentiel



(e) SA linéaire



(f) SA logarithmique

FIGURE 2 – Profils de convergence statistiques par algorithme.

6 Discussion

6.1 Comparaison globale

Les recuits simulés présentent les meilleures performances médianes et la meilleure robustesse (IQR faibles). Le generalized hill-climbing (1, λ) surpasse clairement le hill-climbing (1 + 1) en performance typique et en stabilité.

La recherche aléatoire joue correctement son rôle de baseline, mais reste inférieure en performance médiane.

Données quantitatives de `final_statistics.csv` :

- SA linéaire : médiane = 0.013384, IQR = 0.000778,
- SA exponentiel : médiane = 0.013628, IQR = 0.000886,
- SA logarithmique : médiane = 0.013907, IQR = 0.000680,
- HC (1, λ) : médiane = 0.014776, IQR = 0.001726,

- random search : médiane = 0.023156, IQR = 0.007694,
- HC (1 + 1) : médiane = 0.027007, IQR = 0.028870.

6.2 Impact des contraintes

La pénalisation unifiée a permis :

- de comparer les algorithmes sur une même échelle de coût,
- de rendre rapidement non compétitives les solutions inadmissibles,
- d’observer des phases initiales avec coûts élevés puis retour vers des zones admissibles.

Avec $\rho = 10^6$, le paysage optimisé devient très raide hors faisabilité : de faibles violations produisent immédiatement des coûts de l’ordre de 10^5 à 10^6 , bien plus grands que l’objectif faisable (de l’ordre de 10^{-2}). Cela crée des « murs » de pénalité.

Cette propriété explique la chute abrupte observée au début des courbes : par exemple, pour HC (1, λ), la médiane passe de 1.119×10^6 à l’itération 0 à 1.304×10^3 à l’itération 10, puis à 2.03×10^{-2} vers l’itération 50. Les algorithmes cherchent d’abord à redevenir admissibles, puis seulement à raffiner l’objectif.

Conséquence méthodologique : ce choix favorise fortement la faisabilité précoce, mais peut réduire la finesse d’exploration près de la frontière des contraintes. Une pénalisation adaptative serait une alternative intéressante.

6.3 Stagnation et réchauffement

Le mécanisme de réchauffement est utile lorsque l’algorithme se fige dans un minimum local. Il permet de réintroduire de l’exploration sans perdre l’information du meilleur point courant (retour à la meilleure solution avant relance thermique).

Risque principal : oscillations si le réchauffement est trop fréquent ou trop fort.

Dans notre paramétrage (stagnation 100, facteur 1.5), le réchauffement agit comme une relance contrôlée : il évite l’enfermement durable dans un bassin local tout en conservant la meilleure solution atteinte.

6.4 Refroidissements SA

- Exponentiel : bon compromis convergence/robustesse.
- Linéaire : meilleure médiane observée ici.
- Logarithmique : meilleure stabilité (IQR minimal), convergence plus prudente.

Interprétation théorique : le refroidissement logarithmique est le plus lent. La température décroît moins vite, ce qui maintient plus longtemps une probabilité non négligeable d’accepter des détériorations. Cette exploration prolongée lisse l’effet des tirages aléatoires d’un run à l’autre et réduit la dispersion finale, ce qui est cohérent avec l’IQR observé (0.000680).

À l’inverse, un refroidissement plus agressif intensifie l’exploitation tôt dans la trajectoire : on peut gagner en vitesse ou en médiane selon les cas (ici SA linéaire), mais souvent avec une variabilité un peu plus élevée.

7 Conclusion

Ce TP montre que l’enrichissement du voisinage et l’acceptation stochastique améliorent fortement la robustesse dans un problème contraint.

En synthèse :

- baseline : recherche aléatoire,
- amélioration nette : HC (1, λ) par rapport à HC (1 + 1),
- meilleure performance globale : recuit simulé (valeurs proches de la référence optimale 1.2665×10^{-2}).

Le protocole Monte-Carlo et les profils statistiques donnent une évaluation scientifique reproductible et directement réutilisable pour les travaux ultérieurs.

Référence

Kumar, A., Wu, G., Ali, M. Z., Mallipeddi, R., Suganthan, P. N., & Das, S. (2020). *A test-suite of nonconvex constrained optimization problems from the real-world and some baseline results*. Swarm and Evolutionary Computation, 56, 100693.